

Если выписывать **от простого к сложному**, я бы делал так.

1. Корреляция «одно значение ↔ одно значение»

Сначала просто проверяем ближайшие/одновременные значения без окон:

Связь	Корреляция <i>r</i>
ПАК D15 ↔ ЛИМС D15	+0.89
ПАК сера ↔ ЛИМС сера	+0.34
T90 ↔ T95*	+0.96
T50 ↔ T90*	+0.77
T50 ↔ T95*	+0.72
Сера ↔ D15*	+0.24
Сера ↔ T50*	+0.25
Сера ↔ T90*	+0.22
Сера ↔ T95*	+0.20
Сера ↔ FlashPoint*	-0.07

* корректно трактовать, только если показатели относятся к одной лабораторной пробе.

То есть уже здесь видно: **сера с обычными показателями качества связана слабо**, а показатели фракционного состава между собой — **сильно**.

2. Значение телеметрии с задержкой

Дальше проверяем:

параметр за 30 мин до ЛИМС
параметр за 1 ч
за 2 ч
за 4 ч
за 6 ч
...

Например для **серы** предварительно:

Тег	r	Лучший лаг
F19	+0.267	~1.3 ч
F9	+0.262	~1.3 ч
F26	+0.261	~1.3 ч
F17	+0.257	~1.5 ч

Для **температуры вспышки** связь гораздо сильнее:

Тег	r	Лаг
T18	+0.626	~0.5 ч
T6	-0.565	~1.2 ч
T5	-0.556	~1 ч
F9	-0.549	~1.5 ч
F26	-0.549	~1.5 ч

Для **T95**:

T16 $r \approx -0.36$ лаг ~4.8 ч
P8 $r \approx +0.29$ лаг ~5.5 ч
F25 $r \approx +0.26$ лаг ~4.2 ч
F15 $r \approx +0.24$ лаг ~4.2 ч

Но эти лаги пока **гипотезы**, пока точно не разобрались со временем отбора ЛИМС.

3. Потом уже скользящие окна

То есть вместо одного значения:

F15 за 4 часа до пробы

проверяем:

F15_mean_1h
F15_mean_2h
F15_mean_4h
F15_mean_6h

F15_min_4h
F15_max_4h
F15_std_4h

F15_slope_4h

И смотрим, что лучше коррелирует с target.

Например вполне может оказаться:

F15(t-4h) $r = 0.24$

но

mean(F15, 2-6h) $r = 0.45$

Потому что качество продукта часто зависит **не от одного мгновенного значения, а от режима установки в течение нескольких часов.**

Итого порядок такой:

1. Одно значение ↔ ЛИМС
↓
2. Значение с лагом ↔ ЛИМС
↓
3. Средние по окнам 1/2/4/6 ч
↓
4. min/max/std/trend по окнам
↓
5. Всё это вместе → CatBoost

И уже CatBoost определяет, **какая комбинация параметров и временных окон действительно лучше всего прогнозирует серу/T95/FlashPoint.**